

Bancos Vetoriais e RAG

Uma introdução rápida a dois pilares da IA moderna

O que são Bancos Vetoriais?

Bancos vetoriais são sistemas de armazenamento pensados para guardar e buscar **vetores numéricos de alta dimensão** — as chamadas representações vetoriais (embeddings) de textos, imagens, áudio e outros dados. Ao contrário de um banco relacional comum, que busca por valores exatos, um banco vetorial busca por **similaridade**: dado um vetor de consulta, ele retorna os itens mais 'próximos' matematicamente.

Essa proximidade é calculada por métricas como distância de cosseno, euclidiana ou produto interno. A motivação prática é simples: palavras com significado parecido ficam próximas no espaço vetorial, então 'carro' e 'automóvel' serão vizinhos, mesmo que sejam palavras diferentes.

Tipos de Bancos Vetoriais

Dedicados (Pure Vector DB): construídos do zero para buscas vetoriais, com alta performance e filtragem avançada. Exemplos: Pinecone, Weaviate, Qdrant.

Extensões de bancos relacionais: plugins que adicionam suporte vetorial a bancos já existentes. Exemplo: pgvector para PostgreSQL.

Extensões de motores de busca: suporte vetorial integrado a ferramentas como Elasticsearch e Redis.

In-process / embutidos: rodam direto na memória da aplicação, sem servidor separado. Ideais para testes e projetos menores. Exemplos: FAISS, Chroma, LanceDB.

Multimodais: armazenam e buscam vetores de texto, imagem e áudio no mesmo índice. Exemplo: Weaviate com módulos multimodais.

O que é RAG?

RAG significa **Retrieval-Augmented Generation** — geração aumentada por recuperação. É uma técnica que conecta um LLM (modelo de linguagem) a uma base de conhecimento externa, permitindo que ele consulte informações atualizadas antes de responder.

O problema que o RAG resolve é a **alucinação** dos LLMs: quando o modelo não sabe uma resposta, às vezes inventa uma. Com RAG, ao invés de depender só do que foi visto no treinamento, o modelo busca trechos relevantes em documentos reais e usa isso como base para a resposta.

Como funciona o pipeline básico?

- 1. Indexação (offline):** os documentos são divididos em pedaços (chunks), cada um é convertido em embedding e armazenado no banco vetorial.
- 2. Recuperação:** a pergunta do usuário vira um embedding, e o banco vetorial retorna os chunks mais similares.
- 3. Geração:** os chunks recuperados são enviados junto com a pergunta ao LLM, que gera uma resposta fundamentada nesse contexto.

Tipos de RAG

Naive RAG: a versão mais simples — chunking fixo, busca direta, geração sem etapas extras. Bom para começo, mas limitado.

Advanced RAG: adiciona melhorias como re-ranking dos resultados, reescrita da pergunta e chunking semântico. É o padrão em produção.

Modular RAG: cada parte do pipeline é intercambiável. Permite misturar busca densa e esparsa (hybrid search). Usado em LangChain e LlamaIndex.

Graph RAG: usa grafos de conhecimento para responder perguntas que envolvem múltiplas relações entre entidades. Desenvolvido pela Microsoft.

Agentic RAG: um agente de IA decide sozinho quando buscar, o quê buscar e quantas vezes. Mais poderoso para tarefas complexas.

Multimodal RAG: recupera não só texto, mas também imagens e tabelas. Útil para análise de relatórios com figuras.

Quando usar RAG ao invés de fine-tuning?

Fine-tuning treina o modelo com novos dados, o que é caro e não atualiza em tempo real. RAG é mais barato, permite atualização instantânea da base de conhecimento e deixa rastrear a fonte das respostas. Para a maioria dos casos práticos — chatbots, buscas internas, suporte ao cliente — RAG é a escolha mais eficiente.

Onde é usado na prática?

Chatbots corporativos que consultam documentos internos e políticas da empresa.

Sistemas jurídicos que buscam jurisprudência e cláusulas contratuais.

Assistentes de código como GitHub Copilot Chat, que buscam no repositório.

Plataformas de educação com tutores que citam o material da aula.

Suporte ao cliente com acesso a FAQs e manuais de produto.

Bancos vetoriais são a memória externa dos LLMs. RAG é a ponte que os conecta.